

Capítulo 5

Modelado 2

En este modelo supondremos que las variables cercanas a la fuente puntual están correlacionadas, lo cual se asemeja más a la realidad, pero también es el modelo más complicado a la hora de realizar los cálculos, lo que representa su principal desventaja. Veremos si difiere de suponerlas independientes.

La hipótesis nula es la misma que en el modelo anterior: que las variables son independientes entre sí y que pertenecen a una misma distribución. La hipótesis alternativa es que las variables dentro del círculo están correlacionadas y que el centro del círculo es la fuente puntual, por lo tanto, la distribución conjunta es una función de distribución normal multivariada dada por Σ . Así, las hipótesis son:

$$H_0 : \text{no existe una fuente puntual}$$

vs

$$H_1 : \text{existe una fuente puntual}$$

Covarianza paramétrica

Hug y González definen una función de covarianza al combinar una covarianza exponencial $R_1(s, t) = \sigma^2 e^{-\tau \|t-s\|^m}$ con el proceso de Wiener no estacionario cuya función de covarianza es $R_2(s, t) = \prod_{i=1}^d \min(t_i, s_i)$. Finalmente, se obtiene la función de covarianza paramétrica:

$$R(s_i, s_j) = \sigma^2 \exp \{ -\tau [d(s_i, s_j)] \} \exp \{ \min [(\delta + d(s_i, c))^a, (\delta + d(s_j, c))^a] \}$$

Algunas propiedades del comportamiento de los datos con respecto a la fuente puntual se describen mediante el parámetro a . El parámetro a controla el comportamiento de no estacionaridad. En particular, si $a = 0$, se obtiene la covarianza exponencial estacionaria. Cuando $a > 0$, la varianza aumenta a medida que la fuente puntual se aleja, y disminuye cuando $a < 0$. Este parámetro también controla la correlación entre observaciones con respecto a la fuente puntual.

La función de verosimilitud sera

$$\begin{aligned} L(Z) &= L(x_1, \dots, x_n) = L_1(X_z)L_2(X_{z^c}) \\ &= L_1(\mu_z, \Sigma_z)L_2(\mu_{z^c}, \Sigma_{z^c}) \end{aligned}$$

Para los puntos dentro de la zona

$$\begin{aligned} L_1(\mu_z, \Sigma_z) &= \frac{1}{(2\pi)^{n_z} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right\} \\ \log L_1(\mu_z, \Sigma_z) &= \log \left[\frac{1}{(2\pi)^{n_z} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right\} \right] \\ &= \log \left[\frac{1}{(2\pi)^{n_z} |\Sigma|^{1/2}} \right] + \log \left[\exp \left\{ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right\} \right] \\ &= \log[1] - \log [(2\pi)^{n_z} |\Sigma|^{1/2}] - \frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \\ &= -(\log((2\pi)^{n_z/2}) + \log(|\Sigma|^{1/2}) - \frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu)) \\ &= -\frac{1}{2} [\log((2\pi)^{n_z}) + \log(|\Sigma|) + (x - \mu)^T \Sigma^{-1} (x - \mu)] \end{aligned}$$

pero como

$$R(s_i, s_j) = \sigma^2 \exp\{-\mathcal{T}d(s_i, s_j)\} \exp\{\min[(0,5 + d(s_i, c))^a, (0,5 + d(s_j, c))^a]\}$$

Podemos obtener una matriz E tal que

$$\Sigma = \sigma^2 E$$

Dado que la matriz E es simétrica y cuadrada, se puede afirmar que es diagonalizable. Por lo tanto, aplicando el teorema de descomposición espectral, su determinante es igual al producto de sus eigenvalores. Así

$$|\Sigma| = |\sigma^2 E| = \sigma^{2n_z} |E| = \sigma^{2n_z} \prod_{i=1}^{n_z} \lambda_i$$

Donde los λ_i son los eigenvalores de la matriz E
así

$$\begin{aligned} \log L_1(\mu_z, \Sigma_z) &= -\frac{1}{2} [\log((2\pi)^{n_z}) + \log(|\Sigma|) + (x - \mu)^T \Sigma^{-1} (x - \mu)] \\ &= -\frac{1}{2} \left[n_z * \log((2\pi)) + \log(\sigma^2) + \sum_{i=1}^{n_z} \log(\lambda_i) + (x - \mu)^T \Sigma^{-1} (x - \mu) \right] \end{aligned}$$

Importar librerías

```
1 library(readxl)
2 library(minqa)
```

Importar datos

```
1 # Read the Excel file
2 df <- read_excel("C:/Users/HP/Desktop/Desk/jupyter/database/pole.xls",
3                 col_names = FALSE)
4
5 # Extract data from columns
6 valor1 <- df[[3]]
7 valor2 <- df[[4]]
8 x <- df[[1]]
9 y <- df[[2]]
```

Cálculo de la distancia euclidiana entre dos puntos

```
1 distancia <- function(x1, y1, x2, y2) {
2   return(sqrt((x1 - x2)^2 + (y1 - y2)^2))
3 }
```

Cálculo de distancias desde un punto específico a todos los demás puntos

```
1 distancias_al_punto <- function(x, y, j) {
2   d <- matrix(NA, nrow = length(x), ncol = 2)
3   N <- length(x)
4
5   for (i in 1:N) {
6     d[i, 1] <- distancia(x[j], y[j], x[i], y[i])
7     d[i, 2] <- i
8   }
9
10  return(d)
11 }
```

Determinar puntos dentro o fuera de un círculo

```
1 dentro_fuera <- function(punto, r, X, Y) {
2   dentro <- vector()
3   fuera <- vector()
4   N <- length(X)
5   Distancia <- distancias_al_punto(X, Y, punto)
```

```

6
7   for (i in 1:N) {
8     if (Distancia[i, 1] <= r) {
9       dentro <- c(dentro, Distancia[i, 2])
10    } else {
11      fuera <- c(fuera, Distancia[i, 2])
12    }
13  }
14
15  return(list(dentro = dentro, fuera = fuera))
16 }

```

matriz de covarianza

```

1   cov <- function(s_1x, s_1y, s_2x, s_2y, cx, cy, tao, a) {
2     mini <- min((0.5 + distancia(s_1x, s_1y, cx, cy))^a, (0.5 + distancia(
3       s_2x, s_2y, cx, cy))^a)
4     return(exp(-tao * distancia(s_1x, s_1y, s_2x, s_2y) + mini))
5   }
6
7   matriz_cov <- function(x, y, cx, cy, tao, a) {
8     n <- length(x)
9     cov_1 <- matrix(NA, nrow = n, ncol = n)
10
11    for (i in 1:n) {
12      for (j in 1:n) {
13        cov_1[i, j] <- cov(x[i], y[i], x[j], y[j], cx, cy, tao, a)
14      }
15    }
16
17    return(cov_1)
18 }

```

distribución multivariada

```

1 Distri_Multivariada <- function(sigma, covarianza, x, mu) {
2   n <- length(x)
3   mu <- as.matrix(mu)
4   x <- as.matrix(x)
5
6   # Calcular la descomposición espectral
7   espectral <- eigen(covarianza)
8
9   # Obtener los eigenvalores y eigenvectores
10  eigenvalores <- espectral$values
11  eigenvectores <- espectral$vectors
12
13  # Calcular el determinante a partir de los eigenvalores
14  logdet <- sum(log(eigenvalores))
15
16  inverza <- solve(covarianza)

```

```

17 termino_cuadratico <- t(x - mu) %*% inverza %*% (x - mu)
18
19 return(-1/2 * (n*log(sigma^2) + logdet) - 1/(2 * sigma^2) * termino_
    cuadratico)
20 }

1 Algoritmo_Medias <- function(valor){
2   n <- length(valor)
3   media <- mean(valor)
4   MU <- rep(media, n)
5
6   return (MU)
7 }

```

Selección de elementos en una lista con índices específicos

```

1
2 list_selec <- function(valor, puntos) {
3   X <- vector()
4
5   for (i in puntos) {
6     X <- c(X, valor[i])
7   }
8
9   return(X)
10 }

```

Obtención del Círculo con Máxima Log-Verosimilitud

```

1   L_Z_dentro <- function(punto, r, x, y, valor) {
2     dentroFuera <- dentro_fuera(punto, r, x, y)
3     dentro <- dentroFuera$dentro
4     Valor_Dentro <- list_selec(valor, dentro)
5     corx <- list_selec(x, dentro)
6     cory <- list_selec(y, dentro)
7     cx <- x[punto]
8     cy <- y[punto]
9
10    # mu <- Algoritmo_Medias(cx, cy, Valor_Dentro, corx, cory)
11    mu <- Algoritmo_Medias(Valor_Dentro)
12    f <- function(x_1) {
13      t <- matriz_cov(corx, cory, cx, cy, x_1[2], x_1[3])
14
15      if (!is.na(det(t)) && det(t) > 0.001 ) {
16        return(-Distri_Multivariada(x_1[1], t, Valor_Dentro, mu))
17      }
18    }
19
20

```

```

21
22   initial_guess <- c(1, 2, -1.5)
23   result <- nlminb(initial_guess, lower=c(.0001, .0001,-3),f)
24
25
26   return(list(-result$objective, result$par))
27 }

1   Circulos <- function( radio, num_puntos, x, y){
2   circulos <- list()
3   n <- length(x)
4   k <- 0
5
6   for(i in 1:n){
7     q <- length(dentro_fuera( i, radio, x, y)$dentro)
8     if ( num_puntos <= q ){
9       k <- 1+ k
10      circulos[[k]] <- i
11    }
12  }
13  return (circulos)
14 }

```

Obtención del Círculo con Máxima Log-Verosimilitud

```

1   L <- function(x, y, valor, radio) {
2   Lo <- list()
3   m <- 0
4   a <- list(radio)
5   circulos <- Circulos( radio, 25, x, y)
6
7   for (i in circulos) {
8     for (j in a) {
9       tryCatch({
10        m <- m + 1
11        parametros <- L_Z_dentro(i, j, x, y, valor)
12        Lo[[m]] <- c(parametros[1], i, j, parametros[[2]][1],parametros
13                     [[2]][2],parametros[[2]][3])
14        }, error = function(e) {
15          #cat("Error en la iteraci n", m, ": ", conditionMessage(e), "\n
16              ")
17        })
18      }
19    }
20    return(Lo)
21  }

1 suppressWarnings(lovero<-L(x, y, valor2,3))
2
3
4 # Convertir la lista a un marco de datos
5 mi_marco_datos <- do.call(rbind, lovero)
6 mm <-as.data.frame(mi_marco_datos)

```

```

7
8 # Asignar nombres a las columnas
9 colnames(mm) <- c("log_μve", "punto", "radio", "sigma", "tao", "a")
10
11 # Extraer los n meros de las listas y convertirlos en un vector
    num rico
12 mm$'log ve' <- sapply( mm$'log ve', function(x) x[[1]])
13
14 # Ordenar el data frame por la columna "Edad"
15 df_ordenado <- mm[order( mm$'log ve'), ]
16 # Obtener el ltimo elemento de la lista
17 ultimo_elemento <- tail(df_ordenado, n = 1)
18 ultimo_elemento

1 estadistico <- list()
2   for(i in 1:20){
3
4     conjunto_de_datos <- rnorm(length(valor2), mean=mean(valor2), sd=sd(
        valor2))
5
6     # Mezclar el conjunto de datos
7     conjunto_de_datos <- sample(conjunto_de_datos)
8
9     suppressWarnings(lovero<-L(x, y, conjunto_de_datos,3))
10
11    # Convertir la lista a un marco de datos
12    mi_marco_datos <- do.call(rbind, lovero)
13    mm    <-as.data.frame(mi_marco_datos)
14
15    # Asignar nombres a las columnas
16    colnames(mm) <- c("log_μve", "punto", "radio", "sigma", "tao", "a")
17
18    # Extraer los n meros de las listas y convertirlos en un vector
        num rico
19    mm$'log ve' <- sapply( mm$'log ve', function(x) x[[1]])
20
21    # Ordenar el data frame por la columna "Edad"
22    df_ordenado <- mm[order( mm$'log ve'), ]
23    # Obtener el ltimo elemento de la lista
24    ultimo_elemento <- tail(df_ordenado, n = 1)
25    estadistico[i] <-ultimo_elemento$'log ve'
26
27    print(ultimo_elemento)
28  }

```